VinOps

Alejandro García, Pablo Alfonso López, Antonio Muñoz, Pablo Parrilla Cañadas

2026-02-21

Análisis exploratorio del dataset Wine (VinOps)

Este cuaderno de R contiene el análisis exploratorio de los datos utilizados en el proyecto **VinOps**, cuyo objetivo es diseñar un sistema inteligente capaz de clasificar la variedad vinícola de un vino a partir de sus propiedades fisicoquímicas. El dataset utilizado es el **Wine Recognition Dataset** del repositorio UCI, que contiene 178 muestras de vino descritas mediante 13 variables químicas y una etiqueta de clase correspondiente a tres cultivares distintos.

El propósito de este análisis es comprender la estructura del conjunto de datos antes del desarrollo de los modelos de aprendizaje automático. Para ello se estudian los estadísticos descriptivos, las distribuciones univariantes de las variables, las relaciones de correlación entre características, la estructura multivariante mediante análisis de componentes principales (PCA) y la posible presencia de valores atípicos.

Este análisis permite identificar patrones relevantes, posibles redundancias entre variables y limitaciones del dataset (como su tamaño reducido o la heterogeneidad de escalas), proporcionando así una base sólida para las decisiones de preprocesado y modelado que se abordarán en las siguientes fases del proyecto.

Análisis Exploratorio Inicial

```r
# Cargamos las librerías necesarias
library(readr)
library(factoextra)
library(FactoMineR)
library(knitr)
library(ggplot2)
library(patchwork)
library(grid)
library(gridExtra)
library(corrplot)
library(caret)
library(nnet)
library(MASS)
library(e1071)
library(rpart)
library(randomForest)
library(klaR)
library(kknn)
library(dplyr)
library(caret)
library(mltools)
library(data.table)
```

```r
# Cargamos nuestros datos y revisamos sus estadísticas

vino=read.csv("wine_clean.csv")
summary(vino)
```

```
##      Class          Alcohol        Malic_Acid         Ash
##  Min.   :1.000   Min.   :11.03   Min.   :0.740   Min.   :1.360
##  1st Qu.:1.000   1st Qu.:12.36   1st Qu.:1.603   1st Qu.:2.210
##  Median :2.000   Median :13.05   Median :1.865   Median :2.360
##  Mean   :1.938   Mean   :13.00   Mean   :2.336   Mean   :2.367
##  3rd Qu.:3.000   3rd Qu.:13.68   3rd Qu.:3.083   3rd Qu.:2.558
##  Max.   :3.000   Max.   :14.83   Max.   :5.800   Max.   :3.230
##  Alcalinity_of_Ash   Magnesium      Total_Phenols     Flavanoids
##  Min.   :10.60     Min.   : 70.00   Min.   :0.980   Min.   :0.340
##  1st Qu.:17.20     1st Qu.: 88.00   1st Qu.:1.742   1st Qu.:1.205
##  Median :19.50     Median : 98.00   Median :2.355   Median :2.135
##  Mean   :19.49     Mean   : 99.74   Mean   :2.295   Mean   :2.029
##  3rd Qu.:21.50     3rd Qu.:107.00   3rd Qu.:2.800   3rd Qu.:2.875
##  Max.   :30.00     Max.   :162.00   Max.   :3.880   Max.   :5.080
##  Nonflavanoid_Phenols Proanthocyanins Color_Intensity       Hue
##  Min.   :0.1300       Min.   :0.410   Min.   : 1.280   Min.   :0.4800
##  1st Qu.:0.2700       1st Qu.:1.250   1st Qu.: 3.220   1st Qu.:0.7825
##  Median :0.3400       Median :1.555   Median : 4.690   Median :0.9650
##  Mean   :0.3619       Mean   :1.591   Mean   : 5.058   Mean   :0.9574
##  3rd Qu.:0.4375       3rd Qu.:1.950   3rd Qu.: 6.200   3rd Qu.:1.1200
##  Max.   :0.6600       Max.   :3.580   Max.   :13.000   Max.   :1.7100
##   OD280_OD315       Proline
##  Min.   :1.270   Min.   : 278.0
##  1st Qu.:1.938   1st Qu.: 500.5
##  Median :2.780   Median : 673.5
##  Mean   :2.612   Mean   : 746.9
##  3rd Qu.:3.170   3rd Qu.: 985.0
##  Max.   :4.000   Max.   :1680.0
```

Observamos que todas las variables son numéricas y que no existen valores faltantes, lo que facilitará enormemente el trabajo.

```r
# Una muestra de las primeras 5 filas
head(vino)
```

```
##   Class Alcohol Malic_Acid  Ash Alcalinity_of_Ash Magnesium Total_Phenols
## 1     1   14.23       1.71 2.43              15.6       127          2.80
## 2     1   13.20       1.78 2.14              11.2       100          2.65
## 3     1   13.16       2.36 2.67              18.6       101          2.80
## 4     1   14.37       1.95 2.50              16.8       113          3.85
## 5     1   13.24       2.59 2.87              21.0       118          2.80
## 6     1   14.20       1.76 2.45              15.2       112          3.27
##   Flavanoids Nonflavanoid_Phenols Proanthocyanins Color_Intensity  Hue
## 1       3.06                 0.28            2.29            5.64 1.04
## 2       2.76                 0.26            1.28            4.38 1.05
## 3       3.24                 0.30            2.81            5.68 1.03
## 4       3.49                 0.24            2.18            7.80 0.86
## 5       2.69                 0.39            1.82            4.32 1.04
## 6       3.39                 0.34            1.97            6.75 1.05
##   OD280_OD315 Proline
```

```
## 1        3.92    1065
## 2        3.40    1050
## 3        3.17    1185
## 4        3.45    1480
## 5        2.93     735
## 6        2.85    1450
```

Ahora, visualizaremos las variables mediante histogramas, gráficos de caja y bigotes y gráficos de violín.

```r
# Una función para mostrar por pantalla todas las distribucines de las gráficas.
#Por parejas, para ocupar menos espacio.

plot_histograms=function(vino) {

  cols=names(vino)[sapply(vino, is.numeric)]

  for (i in seq(1, length(cols), by = 2)) {

    par(mfrow = c(1, 2))

    for (j in i:min(i + 1, length(cols))) {
      col=cols[j]

      hist(vino[[col]], main = paste("Histograma de la variabe:\n", col), xlab = col,
col = "#973f5f", border = "white") # Obvio color vino jeje
    }
  }

  par(mfrow = c(1,1))
}

plot_histograms(vino)
```

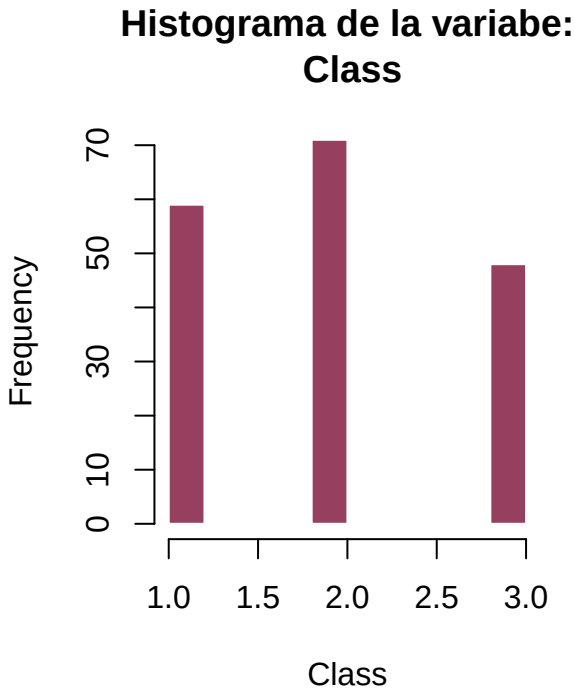
Histograma de la variabe:
Class
Frequency
0
10
30
50
70
1.0
1.5
2.0
2.5
3.0
Class

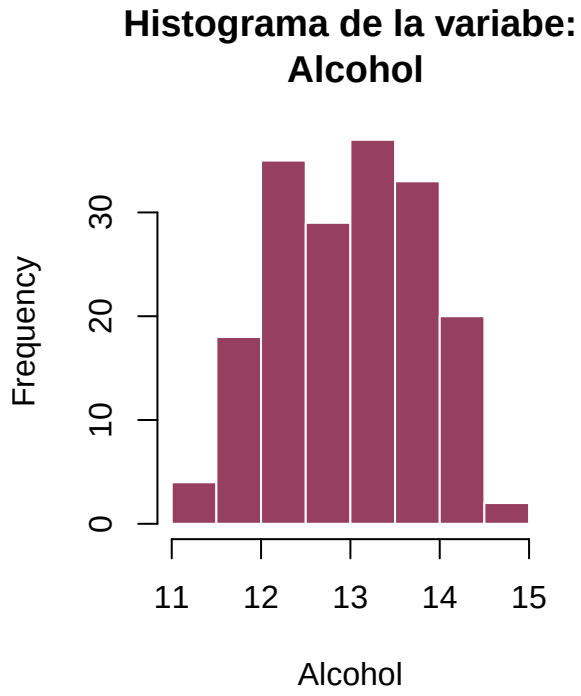
Histograma de la variabe:
Alcohol
Frequency
0
10
20
30
11
12
13
14
15
Alcohol

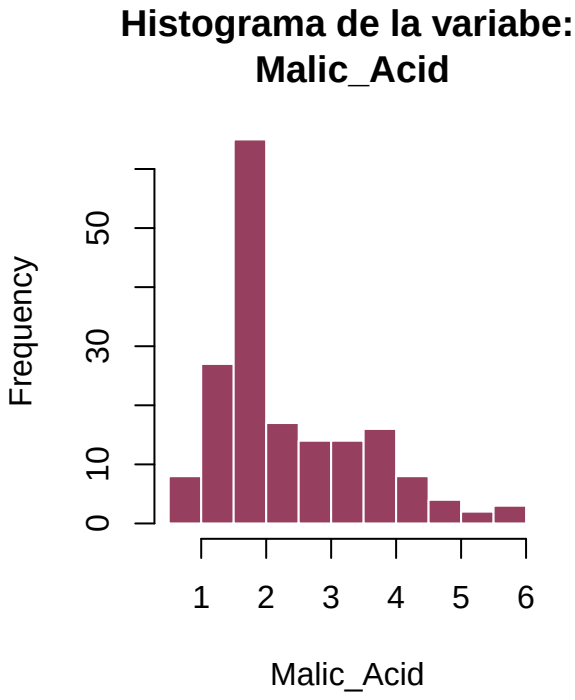
Histograma de la variabe:
Malic_Acid
Frequency
0
10
30
50
1
2
3
4
5
6
Malic_Acid

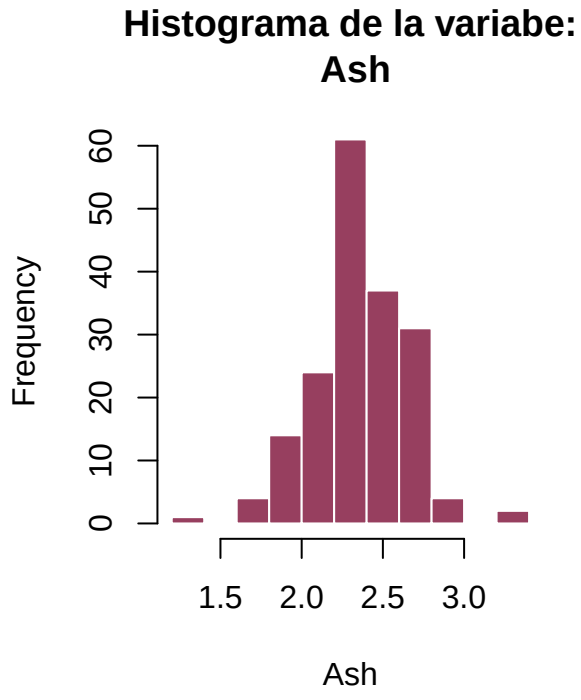
Histograma de la variabe:
Ash
Frequency
0
10
20
30
40
50
60
1.5
2.0
2.5
3.0
Ash

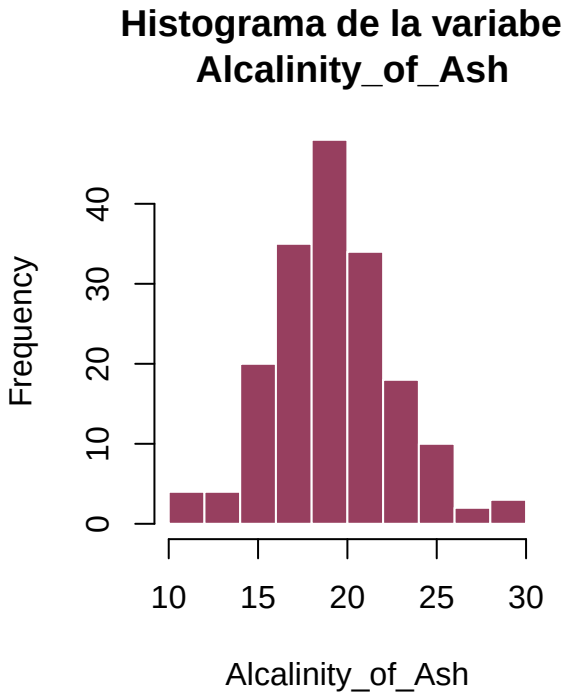
Histograma de la variabe:
Alcalinity_of_Ash
Frequency
0
10
20
30
40
10
15
20
25
30
Alcalinity_of_Ash

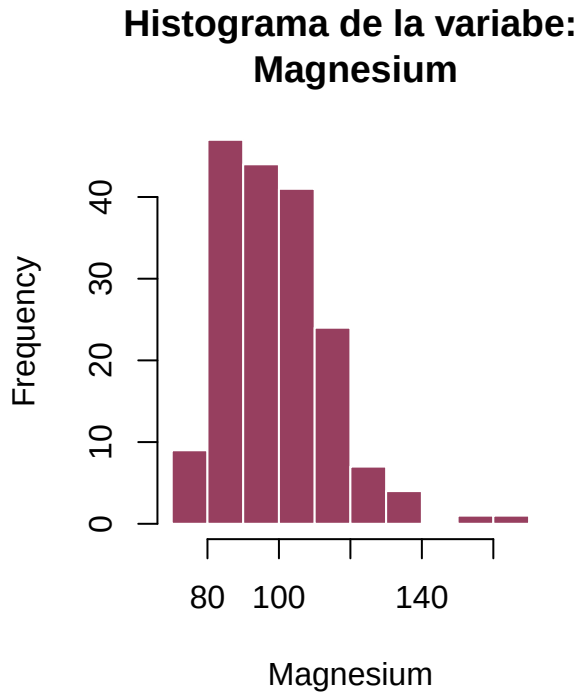
Histograma de la variabe:
Magnesium
Frequency
0
10
20
30
40
80
100
140
Magnesium

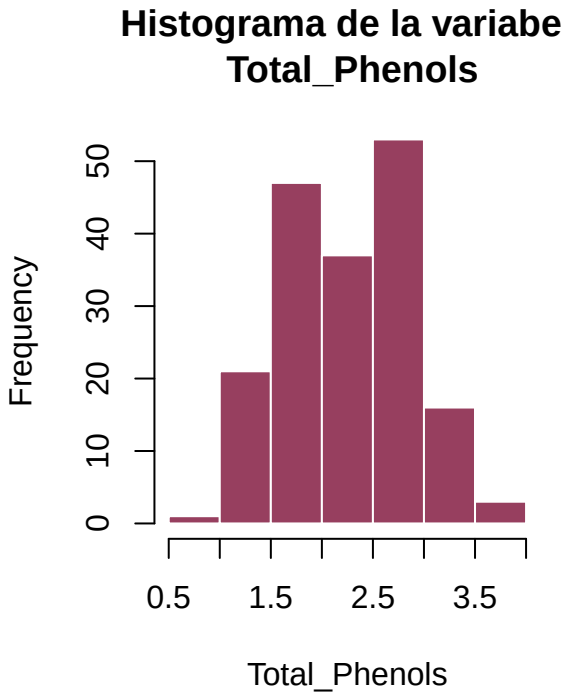
Histograma de la variabe:
Total_Phenols
Frequency
0
10
20
30
40
50
0.5
1.5
2.5
3.5
Total_Phenols

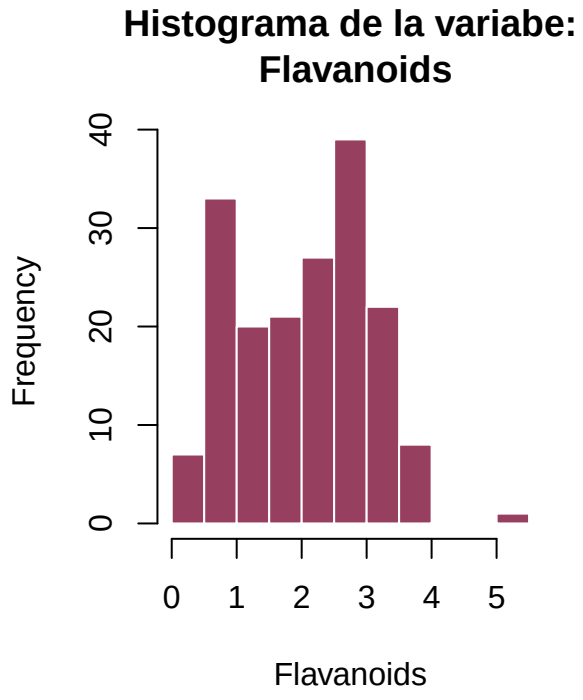
Histograma de la variabe:
Flavanoids
Frequency
0
10
20
30
40
0
1
2
3
4
5
Flavanoids

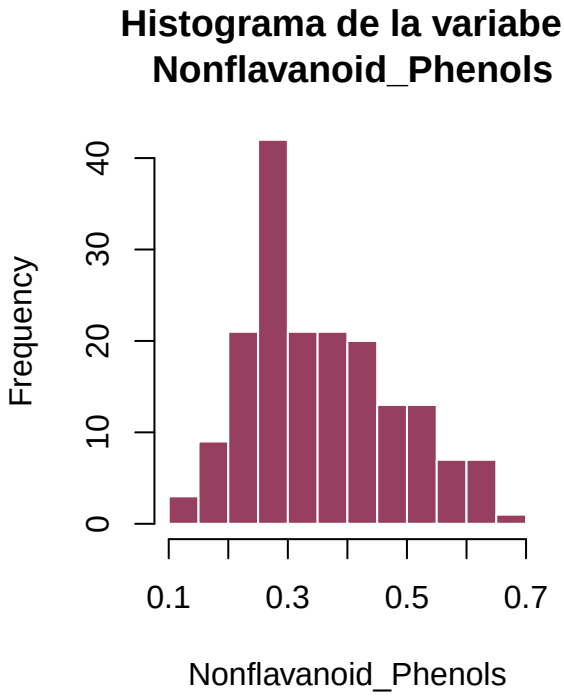
Histograma de la variabe:
Nonflavanoid_Phenols
Frequency
0
10
20
30
40
0.1
0.3
0.5
0.7
Nonflavanoid_Phenols

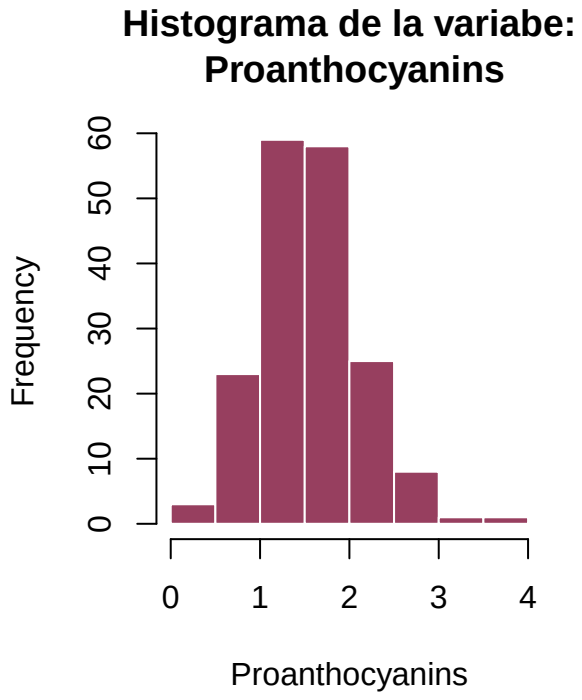
Histograma de la variabe:
Proanthocyanins
Frequency
0
10
20
30
40
50
60
0
1
2
3
4
Proanthocyanins

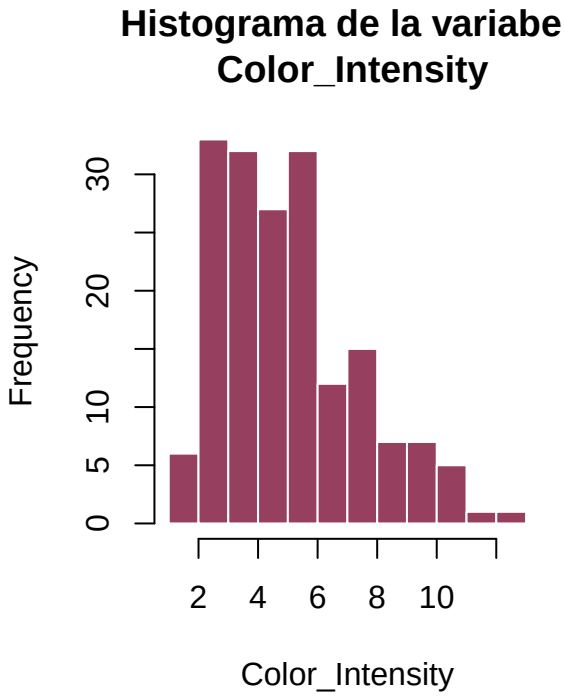
Histograma de la variabe:
Color_Intensity
Frequency
0
5
10
20
30
2
4
6
8
10
Color_Intensity

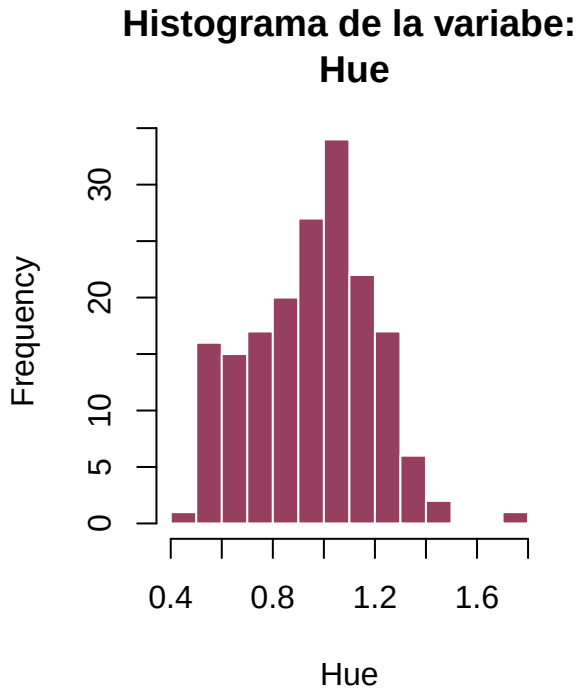
Histograma de la variabe:
Hue
Frequency
0
5
10
20
30
0.4
0.8
1.2
1.6
Hue

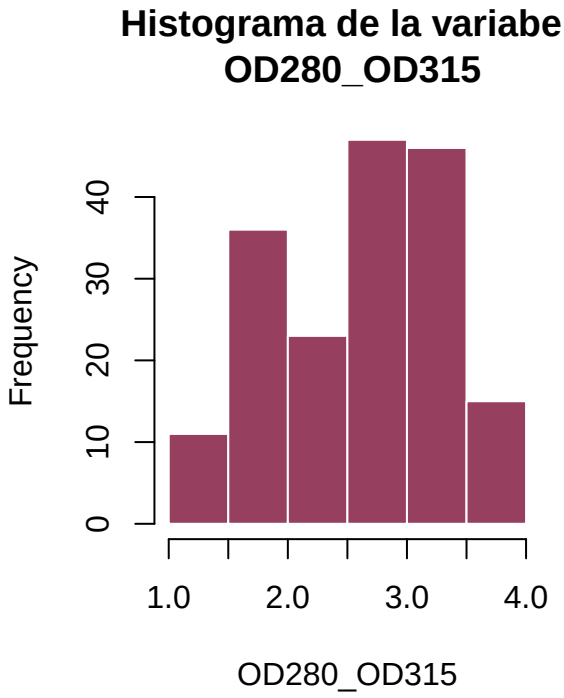

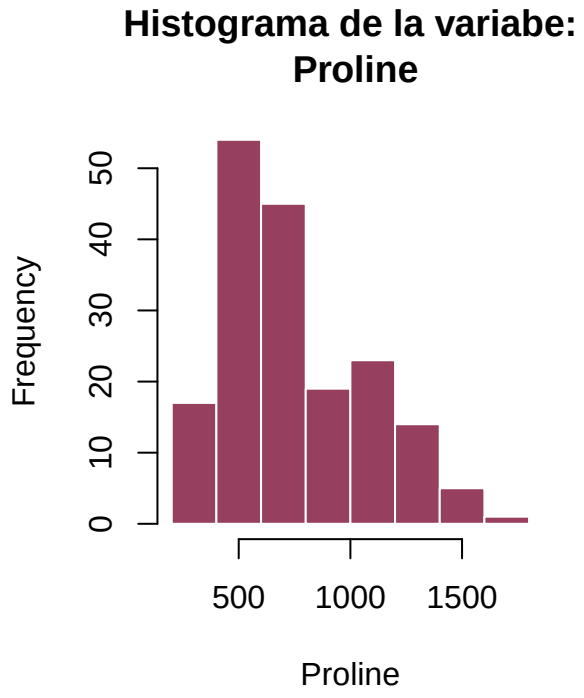

Se puede apreciar cierta asimetría positiva en algunas variables, como el Magnesio, el Ácido Málico, la intensidad del color... Se observan dos modas en los Flavonoides y Fenoles Totales.

```
# Función para mostrar pares de variables con sus respectivos caja y bigotes y
# su violín para mostrar la densidad de manera más específica.
plot_pairs_box_violin=function(vino) {

  num_cols=names(vino)[sapply(vino, is.numeric)]
  n=length(num_cols)

  for (i in seq(1, n, by = 2)) {

    col1=num_cols[i]

    p1_box=ggplot(vino, aes(x = "", y = .data[[col1]])) +
      geom_boxplot(fill = "#973f5f", width = 0.2) +
      labs(title = paste("Diagrama Box-Whiskers de", col1), x = "", y = col1) +
      theme_minimal()

    p1_violin=ggplot(vino, aes(x = "", y = .data[[col1]])) +
      geom_violin(fill = "#c56f94") +
      labs(title = paste("Diagrama de Violín de", col1), x = "", y = col1) +
      theme_minimal() # Te gustan los colores del vino eh

    pair1=p1_box + p1_violin

      col2=num_cols[i + 1]

      p2_box=ggplot(vino, aes(x = "", y = .data[[col2]])) +
        geom_boxplot(fill = "#669b47", width = 0.2) +
```

```
        labs(title = paste("Diagrama Box-Whiskers de", col2), x = "", y = col2) +
        theme_minimal()

      p2_violin=ggplot(vino, aes(x = "", y = .data[[col2]])) +
        geom_violin(fill = "#c7e0b6") +
        labs(title = paste("Diagrama de Violín de", col2), x = "", y = col2) +
        theme_minimal()

      pair2=p2_box + p2_violin
      print(pair1 / pair2)
  }
}

plot_pairs_box_violin(vino)
```

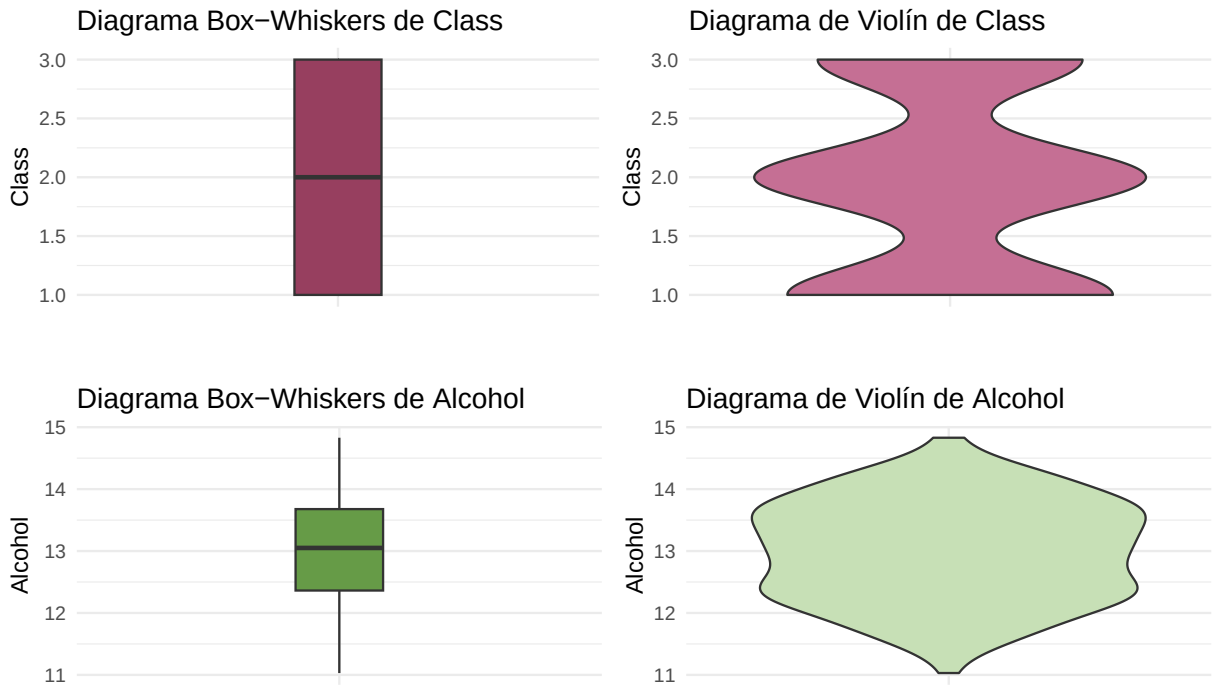

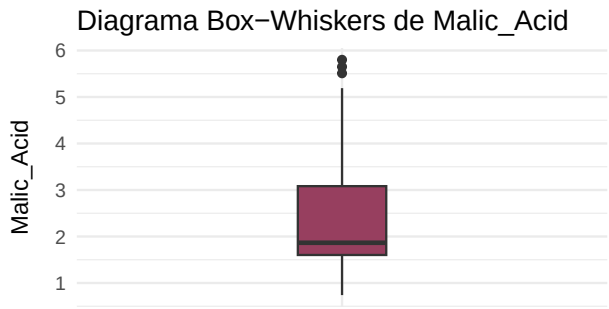
Diagrama Box−Whiskers de Malic_Acid
Malic_Acid
6
5
4
3
2
1

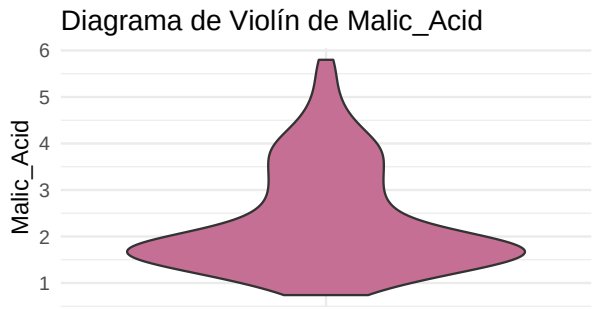
Diagrama de Violín de Malic_Acid
Malic_Acid
6
5
4
3
2
1

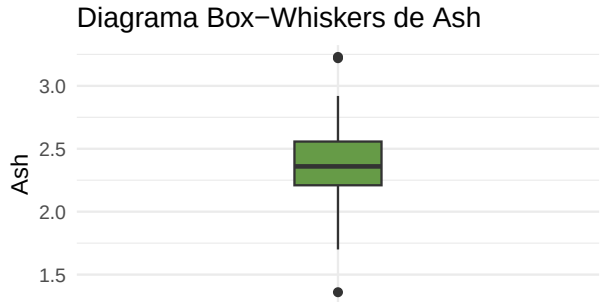
Diagrama Box−Whiskers de Ash
Ash
3.0
2.5
2.0
1.5

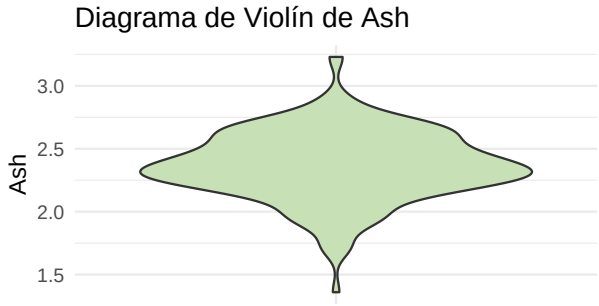
Diagrama de Violín de Ash
Ash
3.0
2.5
2.0
1.5

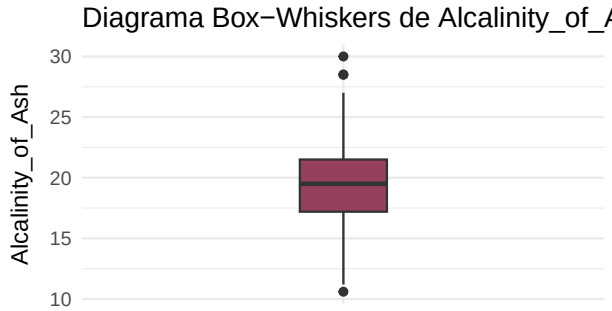
Diagrama Box−Whiskers de Alcalinity_of_Ash
Alcalinity_of_Ash
30
25
20
15
10

Diagrama de Violín de Alcalinity_of_Ash
Alcalinity_of_Ash
30
25
20
15
10

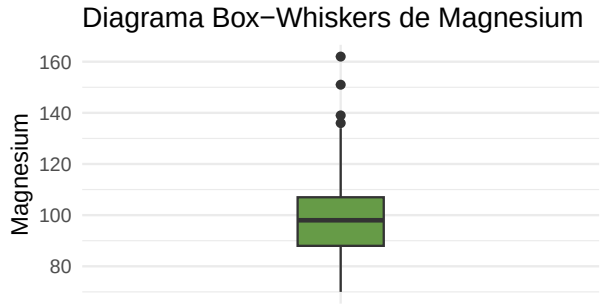
Diagrama Box−Whiskers de Magnesium
Magnesium
160
140
120
100
80

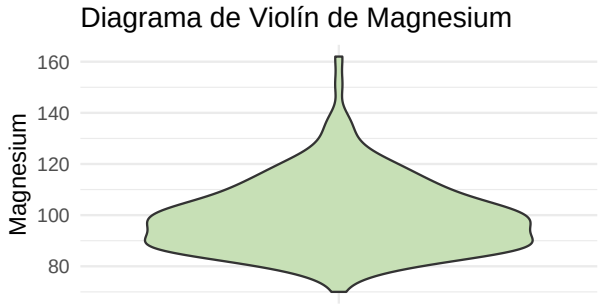
Diagrama de Violín de Magnesium
Magnesium
160
140
120
100
80

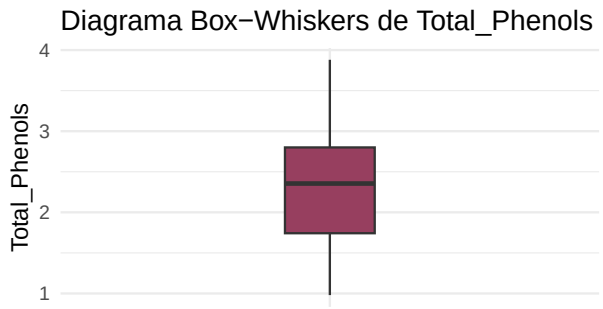
Diagrama Box−Whiskers de Total_Phenols
Total_Phenols
4
3
2
1

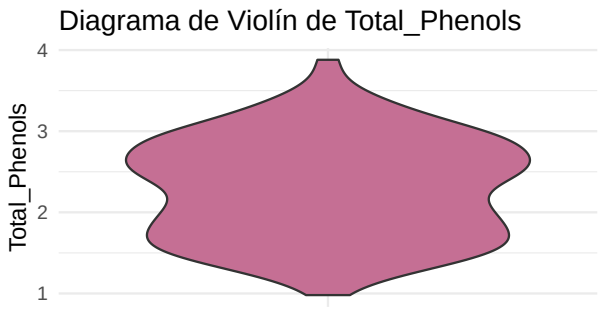
Diagrama de Violín de Total_Phenols
Total_Phenols
4
3
2
1

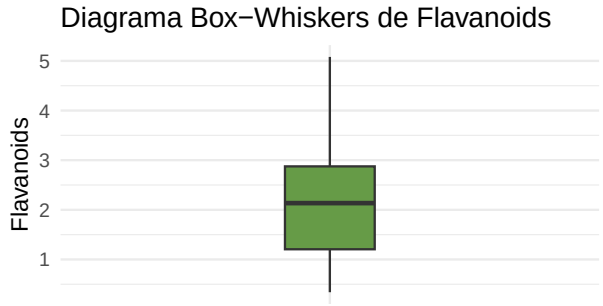
Diagrama Box−Whiskers de Flavanoids
Flavanoids
5
4
3
2
1

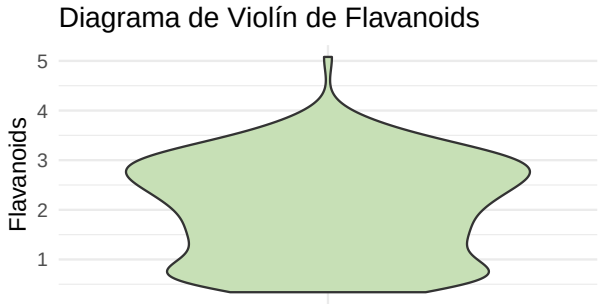
Diagrama de Violín de Flavanoids
Flavanoids
5
4
3
2
1

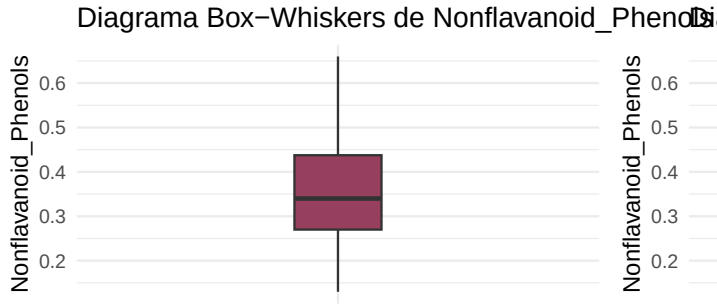
Diagrama Box−Whiskers de Nonflavanoid_Phenols
Nonflavanoid_Phenols
0.6
0.5
0.4
0.3
0.2

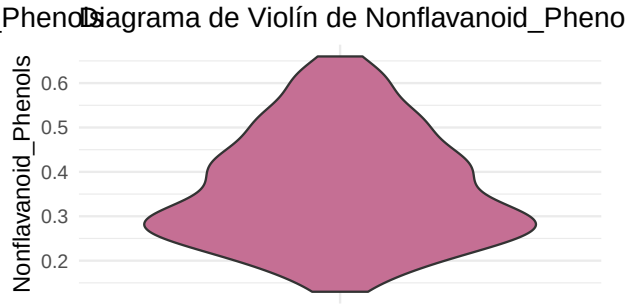
Diagrama de Violín de Nonflavanoid_Pheno
Nonflavanoid_Phenols
0.6
0.5
0.4
0.3
0.2

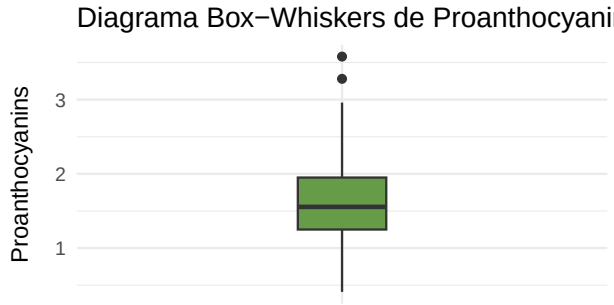
Diagrama Box−Whiskers de Proanthocyanins
Proanthocyanins
3
2
1

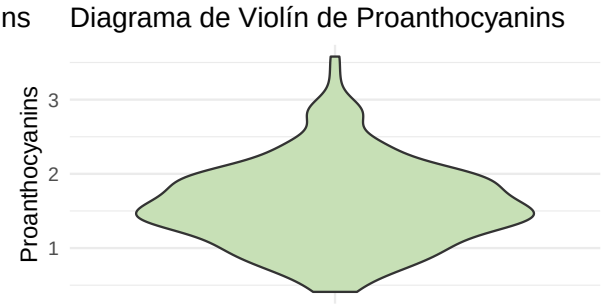
Diagrama de Violín de Proanthocyanins
Proanthocyanins
3
2
1

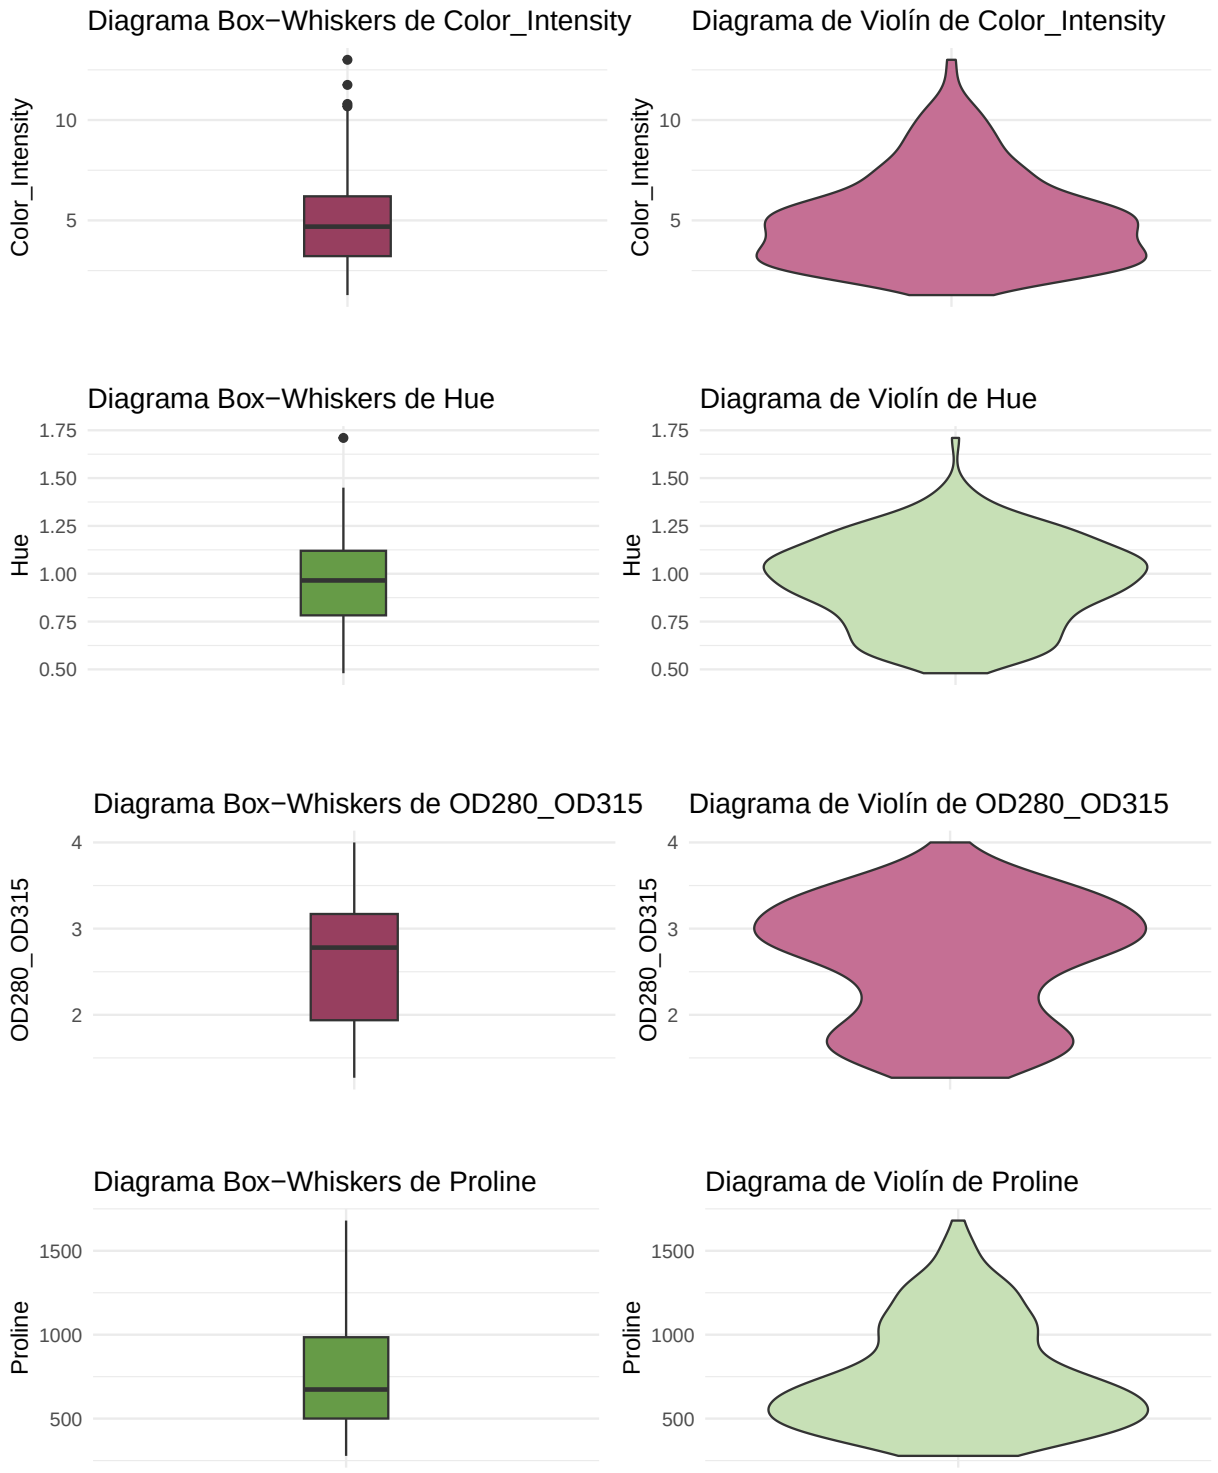

Observamos algunos atípicos mediante los gráficos de caja y bigote, como en Ácido Málico, la Alcalinidad de las cenizas o la intensidad del color. Las distribuciones bimodales desaparecen con el detalle que ofrece el gráfico de violín, quedando nada más el Total de Fenoles y, tal vez, los Flavonoides

Correlación entre las variables

```r
# --- Matriz de correlaciones (Pearson) ---
cor_mat=cor(vino[sapply(vino, is.numeric)], use = "complete.obs", method = "pearson")
corrplot(cor_mat, method = "color", type = "upper",addCoef.col = "black",
         number.cex = 0.6,tl.cex = 0.65, tl.col = "black", diag = FALSE)
```

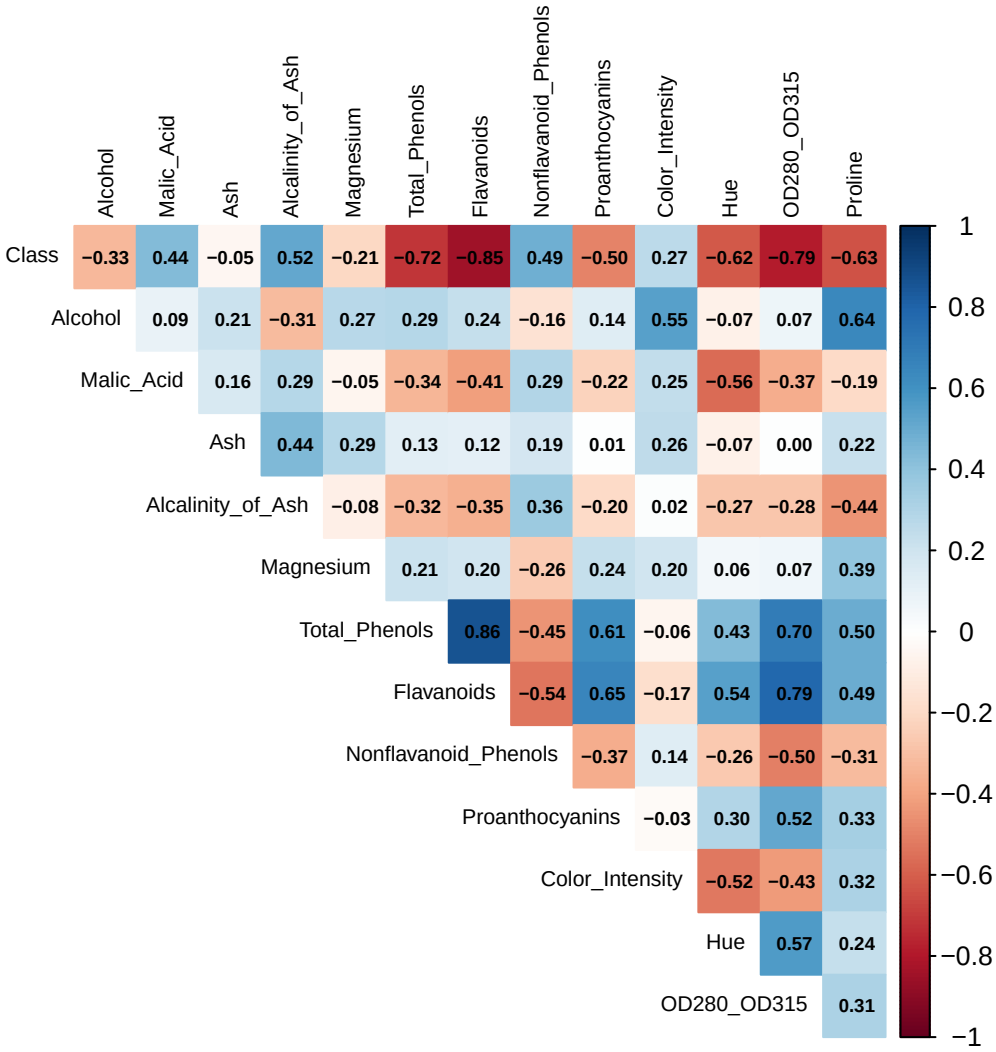

Se observa un bloque claramente correlacionado formado por TotalPhenols, Flavanoids y OD280_OD315, con coeficientes elevados y consistentes. Esta estructura sugiere que estas variables capturan información química parcialmente solapada, posiblemente asociada al contenido fenólico del vino. En términos estadísticos, ello indica la existencia de redundancia informativa y cierto grado de multicolinealidad entre estas características.

Asimismo, Proanthocyanins y Color_Intensity muestran asociaciones relevantes con este grupo, lo que refuerza la idea de que existe un conjunto de variables relacionadas entre sí que describen propiedades químicas conectadas.

Estas relaciones indican la presencia de estructura lineal interna en el dataset y podrían justificar la exploración de técnicas de reducción dimensional en la siguiente sección.

Detección de anomalías por distribución estadísica por clase

El estudio contempla la detección de anomalías utilizando la disitribución estadística por clase. Se utilizará la regla de +- 3 desviaciones típicas, donde todas las observaciones que tengan un valor en una variable por encima o por debajo de ese umbral, será guardada.

```
vino$Class=factor(vino$Class)

vars_num=setdiff(names(vino)[sapply(vino, is.numeric)], "Class")

# Estadísticos por clase y variable
estadisticas_clase=vino %>%
  group_by(Class) %>%
  summarise(across(all_of(vars_num),
                   list(media = mean, sd = sd),
                   .names = "{col}_{fn}"),
            .groups = "drop")

# Lista donde guardaremos las anomalías detectadas
anomalias_univariantes=list()

# Recorremos cada observación
for (i in 1:nrow(vino)) {

  clase_i=vino$Class[i]
  fila_i=vino[i, ]

  # Extraemos la fila de estadísticas correspondiente a su clase
  est_clase=estadisticas_clase %>% filter(Class == clase_i)

  # Recorremos cada variable numérica
  for (var in vars_num) {

    valor=fila_i[[var]]
    media=est_clase[[paste0(var, "_media")]]
    sd=est_clase[[paste0(var, "_sd")]]

    lim_inf=media - 3 * sd
    lim_sup=media + 3 * sd

    # Si se sale del intervalo, la guardamos
    if (valor < lim_inf || valor > lim_sup) {

      anomalias_univariantes[[length(anomalias_univariantes) + 1]]=data.frame(
        Observacion = i,
        Class = as.character(clase_i),
        Variable = var,
        Valor = valor,
        Media_clase = media,
        SD_clase = sd,
        Limite_inferior = lim_inf,
        Limite_superior = lim_sup,
        Tipo_desviacion = ifelse(valor < lim_inf, "Por debajo", "Por encima")
      )
```

```
    }
  }
}

# Convertimos la lista en data frame
anomalias_univariantes_df=bind_rows(anomalias_univariantes)

# Mostramos resultados
kable(anomalias_univariantes_df)
```

Observacion	Class	Variable	Valor	Media_clase	SD_clase	Limite_inferior	Limite_superior	Tipo_desviacion
26	1	Ash	3.22	2.455593	0.2271660	1.7740953	3.137091	Por encima
26	1	Alcalinity_of_Ash	25.00	17.037288	2.5463225	9.3983208	24.676255	Por encima
53	1	Total_Phenols	3.88	2.840170	0.3389614	1.8232854	3.857054	Por encima
70	2	Magnesium	151.00	94.549296	16.7534975	44.2888033	144.809788	Por encima
96	2	Magnesium	162.00	94.549296	16.7534975	44.2888033	144.809788	Por encima
111	2	Proanthocyanins	3.58	1.630282	0.6020678	-0.1759217	3.436485	Por encima
116	2	Hue	1.71	1.056282	0.2029368	0.4474713	1.665092	Por encima
122	2	Ash	3.23	2.244789	0.3154673	1.2983869	3.191190	Por encima
122	2	Flavanoids	5.08	2.080845	0.7057008	-0.0362572	4.197947	Por encima
122	2	Color_Intensity	6.00	3.086620	0.9249293	0.3118320	5.861408	Por encima
124	2	Malic_Acid	5.80	1.932676	1.0155687	-1.1140302	4.979382	Por encima
159	3	Total_Phenols	2.80	1.678750	0.3569709	0.6078374	2.749663	Por encima
159	3	Proanthocyanins	2.70	1.153542	0.4088359	-0.0729659	2.380049	Por encima

Tras aplicar la regla de +- 3 desviaciones típicas, hay observaciones que destacan: 26, 159 y especialment la 122. Este enfoque facilita identificar qué características son responsables de una anomalía Se observa que variables como Magnesium o Total_Phenols concentran varias desviaciones, así como algunas observaciones con múltiples anomalías simultáneas. En general, el número de anomalías es reducido, indicando que la mayoría de las muestras siguen patrones normales.

```
# Índices únicos de observaciones con alguna anomalía univariante
obs_anomalas_univariantes=unique(anomalias_univariantes_df$Observacion)

# Dataset con las filas originales
vino_anomalias_univariantes=vino[obs_anomalas_univariantes, ]

vino_anomalias_univariantes
```

```
##     Class Alcohol Malic_Acid  Ash Alcalinity_of_Ash Magnesium Total_Phenols
## 26      1   13.05       2.05 3.22              25.0       124          2.63
## 53      1   13.82       1.75 2.42              14.0       111          3.88
## 70      2   12.21       1.19 1.75              16.8       151          1.85
## 96      2   12.47       1.52 2.20              19.0       162          2.50
## 111     2   11.46       3.74 1.82              19.5       107          3.18
## 116     2   11.03       1.51 2.20              21.5        85          2.46
## 122     2   11.56       2.05 3.23              28.5       119          3.18
## 124     2   13.05       5.80 2.13              21.5        86          2.62
## 159     3   14.34       1.68 2.70              25.0        98          2.80
##     Flavanoids Nonflavanoid_Phenols Proanthocyanins Color_Intensity  Hue
## 26        2.68                 0.47            1.92            3.58 1.13
## 53        3.74                 0.32            1.87            7.05 1.01
## 70        1.28                 0.14            2.50            2.85 1.28
```

```
## 96        2.27                 0.32            3.28            2.60 1.16
## 111       2.58                 0.24            3.58            2.90 0.75
## 116       2.17                 0.52            2.01            1.90 1.71
## 122       5.08                 0.47            1.87            6.00 0.93
## 124       2.65                 0.30            2.01            2.60 0.73
## 159       1.31                 0.53            2.70           13.00 0.57
##     OD280_OD315 Proline
## 26         3.20     830
## 53         3.26    1190
## 70         3.07     718
## 96         2.63     937
## 111        2.81     562
## 116        2.87     407
## 122        3.69     465
## 124        3.10     380
## 159        1.96     660
```

Guardamos las observaciones completas para posterior examinación por el enólogo.

Análisis de Componentes Principales (PCA) para análisis exploratorio

```r
# Pasamos a factor nuestra variable objetivo para poder utilizarla.
vino$Class=factor(vino$Class)

res.pca = PCA(vino, scale.unit = TRUE, graph = FALSE, ncp = 10, quali.sup = 1)
# Ponemos 10 componentes principales para visualizar y utilizamos la primera
#variable (la clase) como variable cualitativa complementaria
eig.val=get_eigenvalue(res.pca) # Sacamos sus componentes principales y la varianza explicada
eig.val[1:6,]
```

```
##       eigenvalue variance.percent cumulative.variance.percent
## Dim.1  4.7058503        36.198848                    36.19885
## Dim.2  2.4969737        19.207490                    55.40634
## Dim.3  1.4460720        11.123631                    66.52997
## Dim.4  0.9189739         7.069030                    73.59900
## Dim.5  0.8532282         6.563294                    80.16229
## Dim.6  0.6416570         4.935823                    85.09812
```

Aparentemente, lo ideal sería coger 5 componentes, ya que con ellas alcanzamos el 80% de varianza explicada, a pesar de que la quinta dimensión no aporte mucho más que la cuarta.

```r
# Visualizamos la varianza explicada por las componentes principales.
fviz_eig(res.pca, addlabels = TRUE)
```

```
## Warning in geom_bar(stat = "identity", fill = barfill, color = barcolor, :
## Ignoring empty aesthetic: `width`.
```

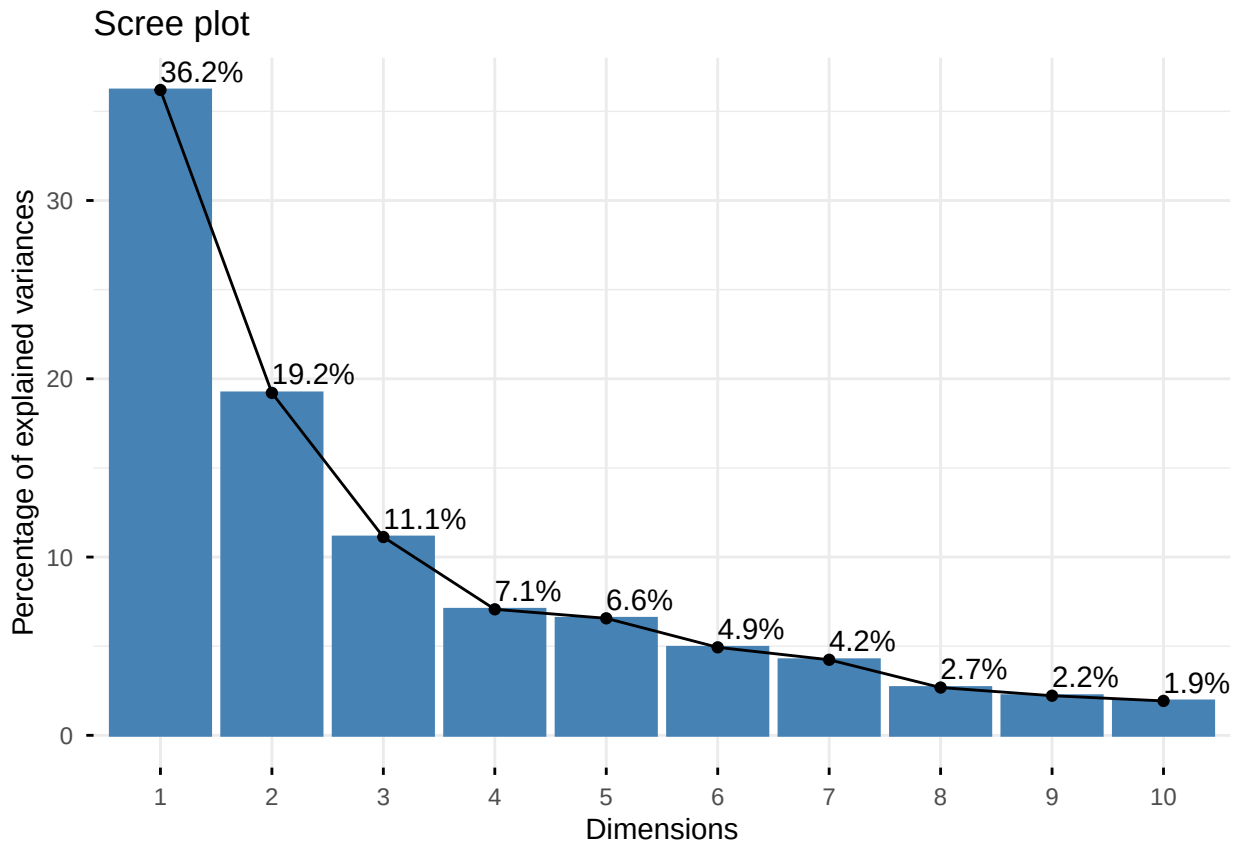


```
K = 5
res.pca = PCA(vino, scale.unit = TRUE, graph = FALSE, ncp = K, quali.sup = 1)
```

A pesar de que el criterio del codo demandaría coger solo 4 componentes, nos encontramos ante un problema pequeño en el que podríamos llegar al 80% de varianza explicada con solamente esa quinta componente, así que la utilizaremos para nuestro estudio. El uso de solamente 5 componentes para obtener un 80% de varianza es indicativo de que nuestras variables se encuentran bastante correlacionadas, como hemos visto anteriormente. La ventaja de este método es que, al ser todas las componentes ortogonales (perpendiculares entre ellas en diferentes planos) y no tener correlación, podemos sortear el escollo de la multicolinealidad en caso de haberlo.

Detección de anómalos

Aunque ya hemos detectado atípicos a través del gráfico de caja y bigotes, vamos a realizar una detección utilizando nuestro modelo PCA, usando la T^2 de Hottelling y la distancia al modelo, aunque no los eliminaremos hasta que preparemos el modelado.

```
# Gráfico T2 Hotelling
misScores = res.pca$ind$coord[,1:K]
miT2 = colSums(t(misScores**2) / eig.val[1:K,1])
I = nrow(vino)
F95 = K*(I**2 - 1)/(I*(I - K)) * qf(0.95, K, I-K)
F99 = K*(I**2 - 1)/(I*(I - K)) * qf(0.99, K, I-K)
plot(1:length(miT2), miT2, type = "l", xlab = "Atributos", ylab = "T2")
abline(h = F95, col = "orange", lty = 2, lwd = 2)
abline(h = F99, col = "red3", lty = 2, lwd = 2)
```

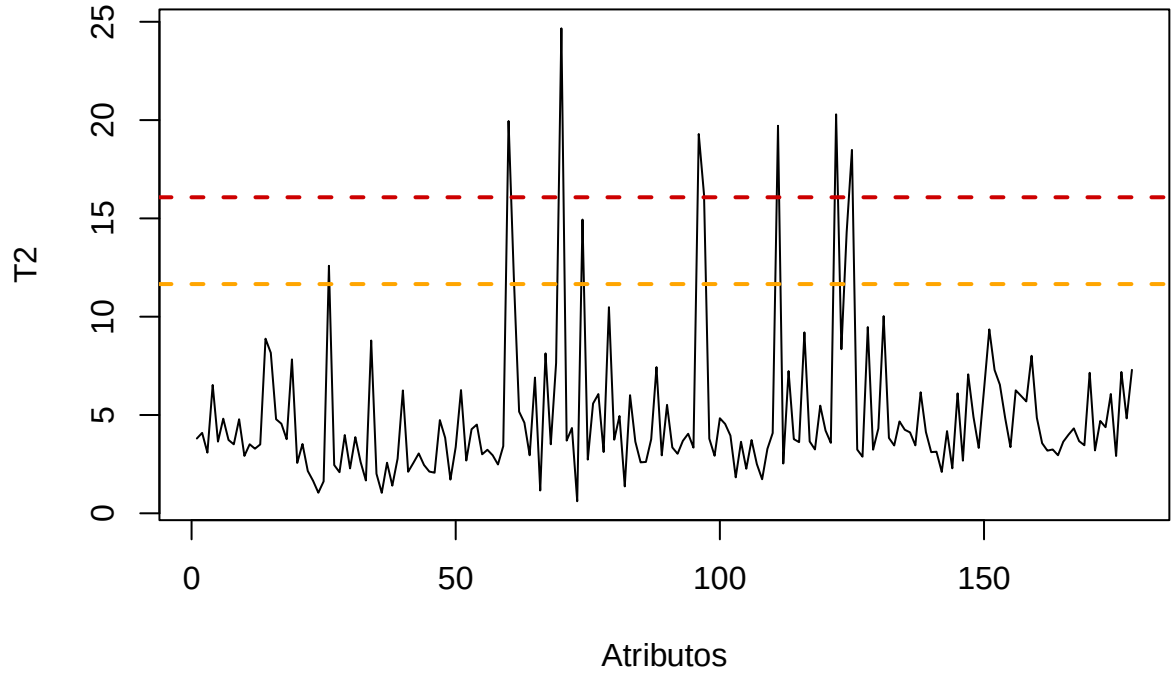


```
anomalas_5 = which(miT2 > F95)
anomalas_5
```

```
##  26  60  61  70  74  96  97 111 122 124 125
##  26  60  61  70  74  96  97 111 122 124 125
```

```
anomalas_99= which(miT2 > F99)
anomalas_99
```

```
##  60  70  96  97 111 122 125
##  60  70  96  97 111 122 125
```

En el gráifco podemos observar que, usando la T^2 de Hottelling, vemos que existen varios individuos atípicos, concretamente 11, de las cuales, 5 son atípicos extremos. Llama la atención la 26 y la 122, pues ya llamaron la atención en la detección de anomalías.

```
# Score plots
p1 = fviz_pca_ind(res.pca, axes = c(1,2), geom = c("point"), habillage = factor(miT2 > F95))
p2 = fviz_pca_ind(res.pca, axes = c(3,4), geom = c("point"), habillage = factor(miT2 > F95))
grid.arrange(p1,p2, nrow = 1)
```

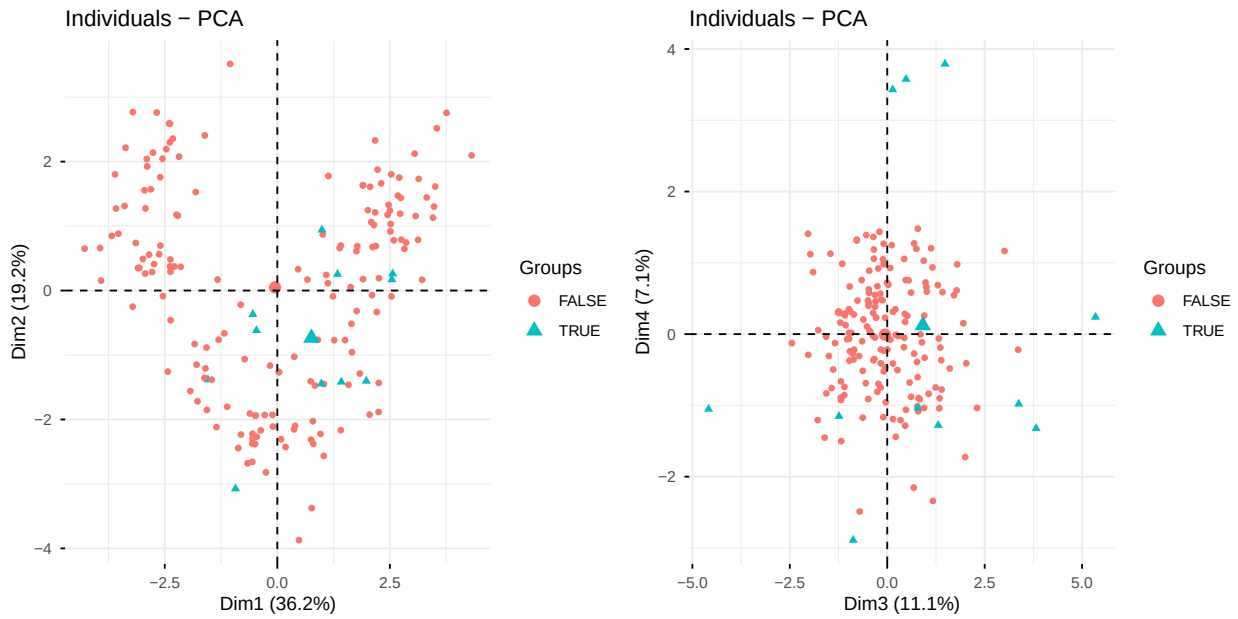

Utilizando la proyección de las primeras cuatro dimensiones, observamos que en las dos primeras dimensiones, los valores no están demasiados alejados del centro. Sin embargo, en la tercera y cuarta dimensión sí puede verse que se encuentran más alejands que la mayoría de puntos.

Ahora, detectaremos anómalos utilizando la distancia al modelo

```
# Distancia al modelo
vino_num=vino[, sapply(vino, is.numeric), drop = FALSE]
if ("Class" %in% colnames(vino_num))
  vino_num=vino_num[, setdiff(colnames(vino_num), "Class"), drop = FALSE]

X=scale(vino_num, center = TRUE, scale = TRUE)
X=as.matrix(X)

misLoadings=sweep(res.pca$var$coord[, 1:K, drop = FALSE],
                  2, sqrt(res.pca$eig[1:K, 1]), FUN = "/")


myE=X - misScores %*% t(misLoadings)
mySCR=rowSums(myE^2)

plot(1:length(mySCR), mySCR, type = "l",
     main = "Distancia al modelo (SPE / Q-residuals)",
     ylab = "SCR", xlab = "Observaciones")

# Límites
g=var(mySCR) / (2 * mean(mySCR))
h=(2 * mean(mySCR)^2) / var(mySCR)

chi2lim95=g * qchisq(0.95, df = h)
chi2lim99=g * qchisq(0.99, df = h)

abline(h = chi2lim95, col = "orange", lty = 2, lwd = 2)
abline(h = chi2lim99, col = "red3",  lty = 2, lwd = 2)
```

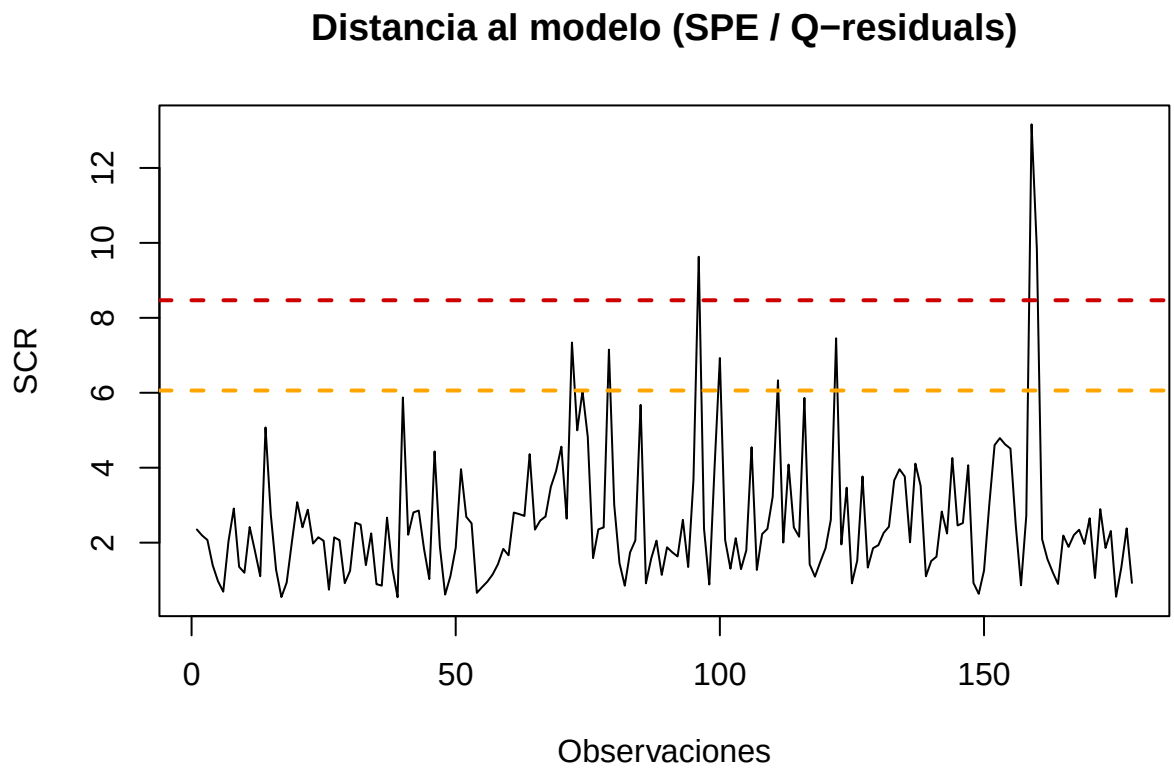


```
# índices de outliers por SPE
out_SPE_moderados=which(mySCR > chi2lim95 & mySCR <= chi2lim99)
out_SPE_extremos =which(mySCR > chi2lim99)

out_SPE_moderados
```

```
## [1]  72  79 100 111 122
```

```
out_SPE_extremos
```

```
## [1]  96 159 160
```

Utilizando la distancia al modelo, podemos observar que tenemos un número menos de atípicos, pues aquí disponemos de 8 valores atípicos: 5 moderados y 3 extremos.

```
# Score plots
p1 = fviz_pca_ind(res.pca, axes = c(1,2), geom = c("point"), habillage = factor(mySCR > chi2lim95))
p2 = fviz_pca_ind(res.pca, axes = c(3,4), geom = c("point"), habillage = factor(mySCR > chi2lim95))
grid.arrange(p1,p2, nrow = 1)
```

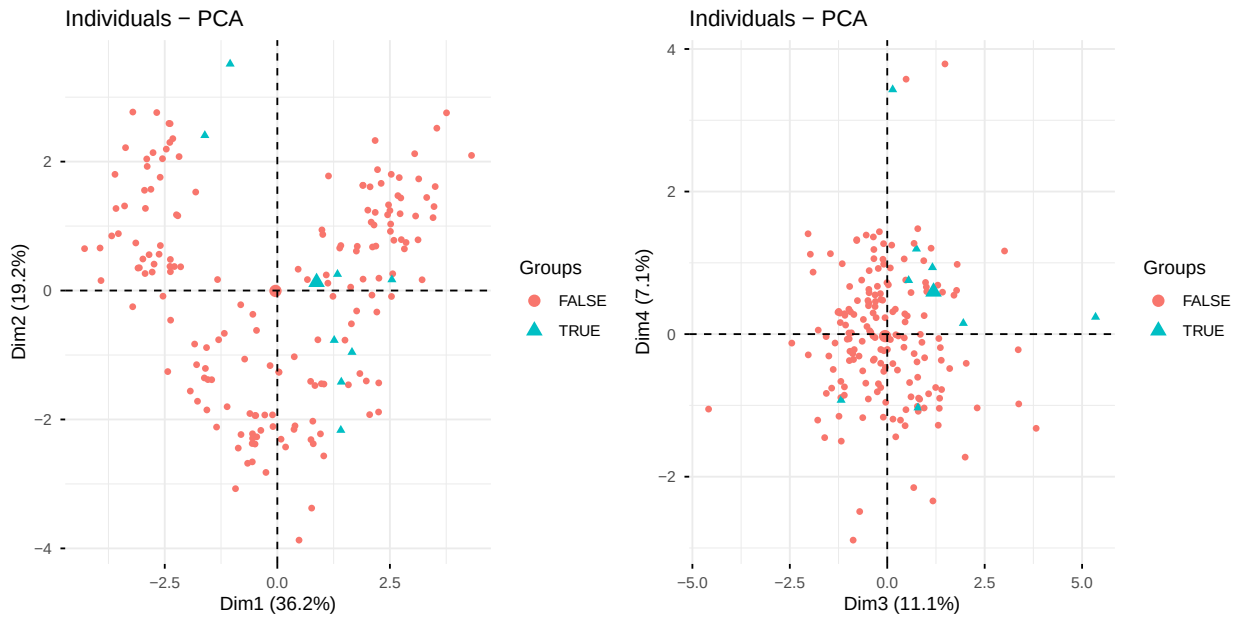

De manera similar a la T^2 de Hottelling, se puede observar como en primera y segunda dimensión se encuentran algo más centrados con dos valores más alejados en segunda dimensión. Sin embargo, en tercera y cuarta dimensión hay puntos algo más centrados con 2 más alejados cada uno en una dimensjión, de manera similar a las dos primeras componentes.

Ahora con los extremos, vamos a intersectarlos para ver si son los mismos en ambos métodos.

```
# Todos de ambos
out_moderados=which(miT2 > F95 & miT2 <= F99)
out_extremos= which(miT2 > F99)

out_T2_total =sort(unique(c(out_moderados, out_extremos)))
out_SCR_total=sort(unique(c(out_SPE_moderados, out_SPE_extremos)))

# Diferencias
out_coinciden_total=sort(intersect(out_T2_total, out_SCR_total))
out_solo_T2=sort(setdiff(out_T2_total, out_SCR_total))
out_solo_SCR=sort(setdiff(out_SCR_total, out_T2_total))

# Coincidencias completas
out_coinciden_moderados=sort(intersect(out_moderados, out_SPE_moderados))
out_coinciden_extremos =sort(intersect(out_extremos,  out_SPE_extremos))

# Coincidencias mixtas
out_T2_mod_SCR_ext=sort(intersect(out_moderados, out_SPE_extremos))
out_T2_ext_SCR_mod=sort(intersect(out_extremos,  out_SPE_moderados))

# Vista bonita en consola
cat("\n--- Resumen comparación T² vs SCR ---\n")
```

```
##
## --- Resumen comparación T² vs SCR ---
```

```
cat("T² total:", length(out_T2_total), " | SCR total:", length(out_SCR_total), "\n")
```

```
## T² total: 11  | SCR total: 8
```

```r
cat("Coinciden (total):", length(out_coinciden_total), "\n")
```

```
## Coinciden (total): 3
```

```r
cat("Solo T²:", length(out_solo_T2), " | Solo SCR:", length(out_solo_SCR), "\n")
```

```
## Solo T²: 8  | Solo SCR: 5
```

```r
cat("\n--- Por gravedad ---\n")
```

```
##
## --- Por gravedad ---
```

```r
cat("Coinciden moderados (T² y SCR):", length(out_coinciden_moderados), "\n")
```

```
## Coinciden moderados (T² y SCR): 0
```

```r
cat("Coinciden extremos  (T² y SCR):", length(out_coinciden_extremos), "\n")
```

```
## Coinciden extremos  (T² y SCR): 1
```

```r
cat("T² moderado & SCR extremo:", length(out_T2_mod_SCR_ext), "\n")
```

```
## T² moderado & SCR extremo: 0
```

```r
cat("T² extremo  & SCR moderado:", length(out_T2_ext_SCR_mod), "\n")
```

```
## T² extremo  & SCR moderado: 2
```

Exploración de los datos usando PCA

Finalmente, visualizaremos los datos en las proyecciones del Análisis de Componentes Principales para observar cómo están distribuidos y qué variables aportan más a cada componente.

```r
fviz_pca_var(res.pca, axes = c(1,2), repel = TRUE, col.var = "contrib",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"))
```

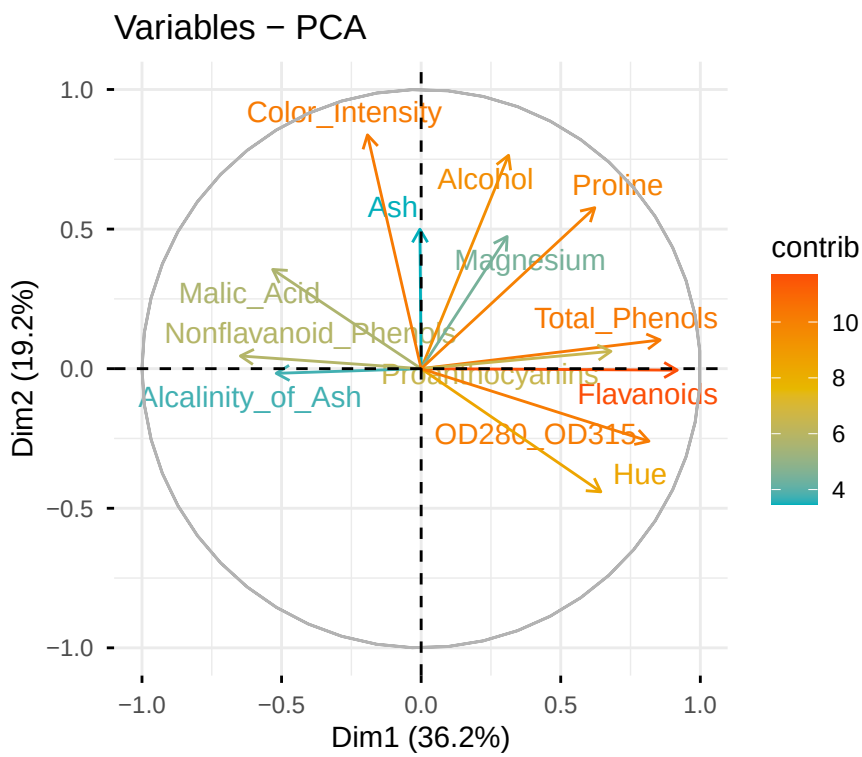


```
fviz_pca_var(res.pca, axes = c(3,4), repel = TRUE, col.var = "contrib",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"))
```

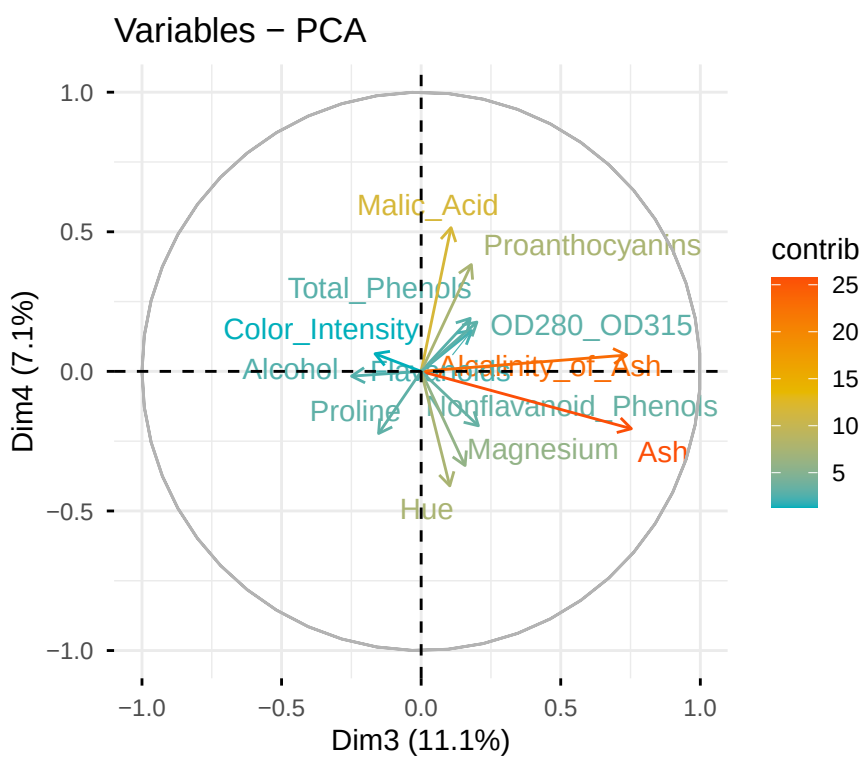

```r
misLoadings
```

```
##                            Dim.1        Dim.2       Dim.3       Dim.4
## Alcohol               0.144329395  0.483651548 -0.20738262 -0.01785630
## Malic_Acid           -0.245187580  0.224930935  0.08901289  0.53689028
## Ash                  -0.002051061  0.316068814  0.62622390 -0.21417556
## Alcalinity_of_Ash    -0.239320405 -0.010590502  0.61208035  0.06085941
## Magnesium             0.141992042  0.299634003  0.13075693 -0.35179658
## Total_Phenols         0.394660845  0.065039512  0.14617896  0.19806835
## Flavanoids            0.422934297 -0.003359812  0.15068190  0.15229479
## Nonflavanoid_Phenols -0.298533103  0.028779488  0.17036816 -0.20330102
## Proanthocyanins       0.313429488  0.039301722  0.14945431  0.39905653
## Color_Intensity      -0.088616705  0.529995672 -0.13730621  0.06592568
## Hue                   0.296714564 -0.279235148  0.08522192 -0.42777141
## OD280_OD315           0.376167411 -0.164496193  0.16600459  0.18412074
## Proline               0.286752227  0.364902832 -0.12674592 -0.23207086
##                           Dim.5
## Alcohol               0.26566365
## Malic_Acid           -0.03521363
## Ash                   0.14302547
## Alcalinity_of_Ash    -0.06610294
## Magnesium            -0.72704851
## Total_Phenols         0.14931841
## Flavanoids            0.10902584
## Nonflavanoid_Phenols  0.50070298
## Proanthocyanins      -0.13685982
## Color_Intensity       0.07643678
## Hue                   0.17361452
## OD280_OD315           0.10116099
## Proline               0.15786880
```

Se puede observar que la primera dimensión está fuertemente influida por variables relacionadas con el contenido fenólico (Flavonoides, Total de Fenoles y OD280/OD315), lo que sugiere que esta componente recoge un eje asociado a la riqueza polifenólica del vino.

La segunda dimensión está principalmente determinada por la Intensidad del color, Ácido Málico y prolina, de manera que la segunda dimensión para aportar cierta relevancia química.

La tercera dimensión parece tener principalmente influencia por parte de las cenizas del vino y su alcalinidad, mientras que en la cuarta solamente destacan el Ácido Málico y un poco los proantocianidinas.

Finalmente, la quinta dimensión está principalmente influida por el Magnesio, con una carga negativa elevada, y en menor medida por los Fenoles no flavonoides, lo que indica que esta componente recoge variaciones asociadas principalmente al contenido mineral del vino.

```r
# Gráfico de scores para todos los individuos coloreados por Clase
fviz_pca_ind(res.pca, axes = c(1,2), geom = c("point", "text"),
             repel = TRUE, labelsize = 2, habillage = "Class")
```

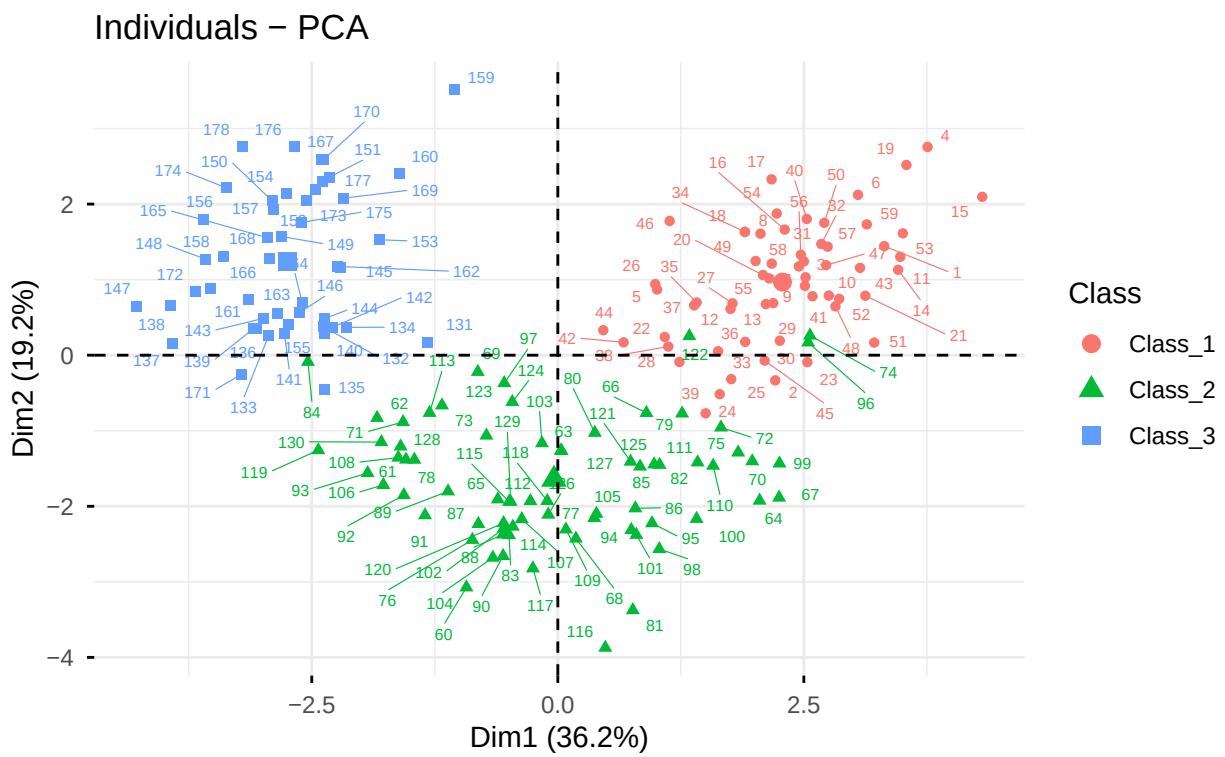


```
fviz_pca_ind(res.pca, axes = c(3,4), geom = c("point", "text"),
             repel = TRUE, labelsize = 2, habillage = "Class")
```

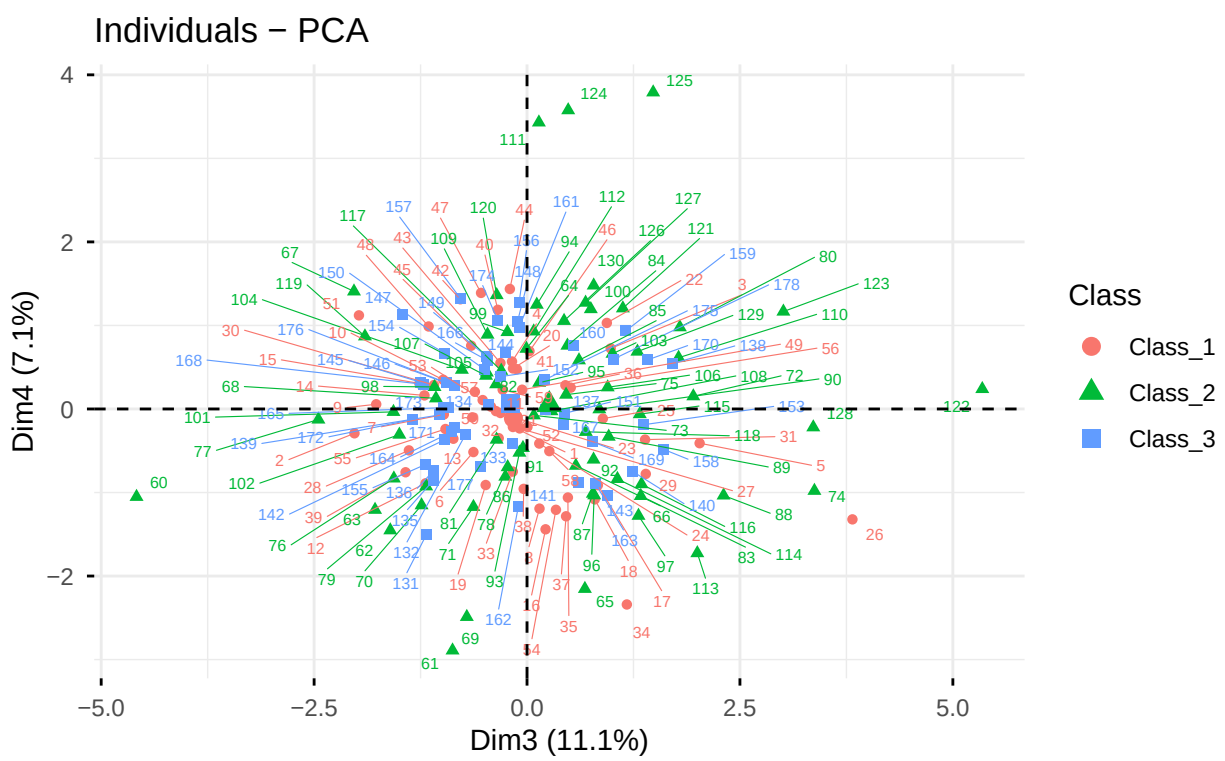

En el primer gráfico de scores, se puede observar como, solamente con dos dimensiones, todos los individuos por clase se pueden ver bastante bien separados. Esto es un buen indicativo de cara al modelado y la

predicción de sus clases. Se puede ver como la clase 2 puede encontrarse algo solapada con las clases 1 y 2, pero como estas dos últimas sí están completamente diferenciadas entre ellas.

Sin embargo, la visualización de la tercera y cuarta dimensión es complicado extraer conclusiones, ya que se ven todos los individuos entremezclados y no es posible extraer conclusiones claras..

```
fviz_pca_biplot(X = res.pca, axes = c(1,2),geom=c("point"), repel="TRUE",habillage = "Class")
```

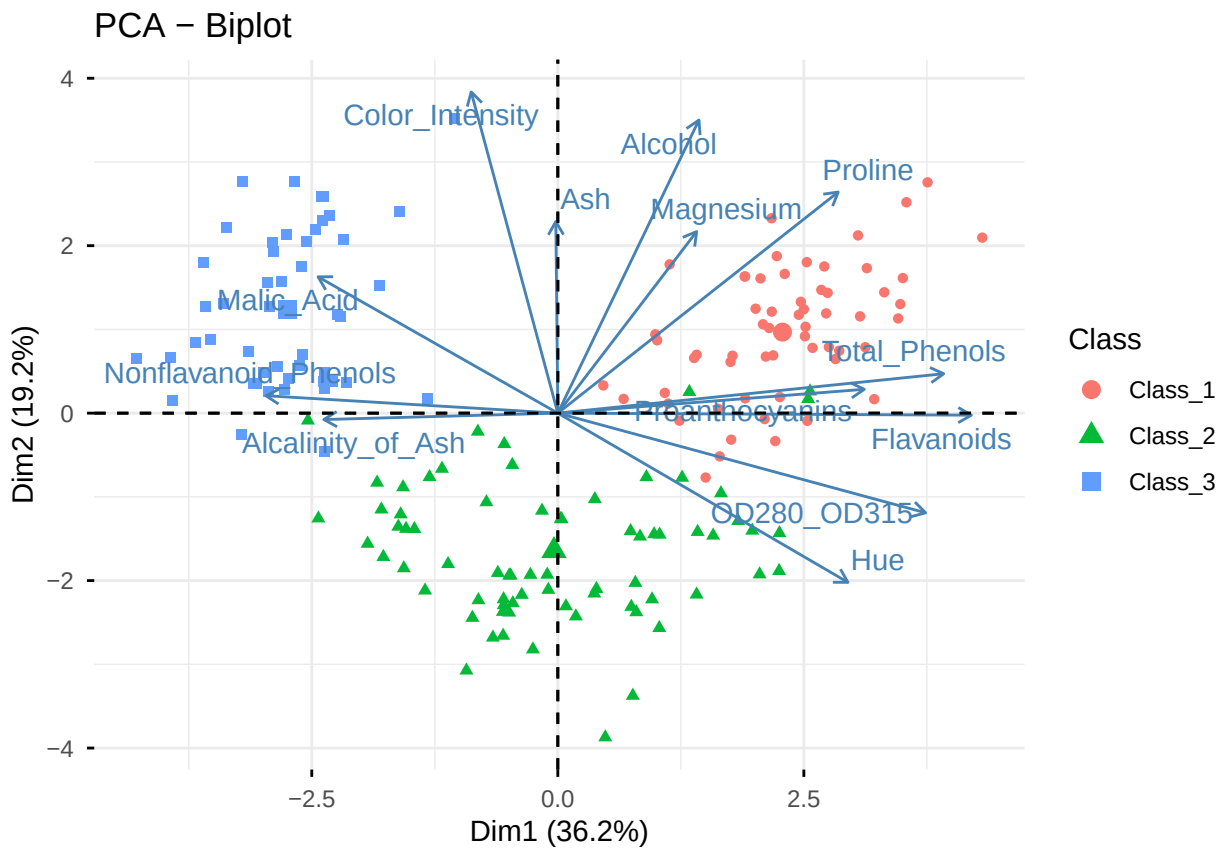

En el biplot se observa que la Clase 1 se concentra principalmente en la zona positiva de la primera dimensión, alineada con las direcciones de Flavonoides, Fenoles Totales, OD280/OD315 y Prolina, lo que sugiere que estos vinos presentan valores relativamente altos en dichas variables. Por el contrario, la Clase 3 se sitúa mayoritariamente en la región negativa de la primera componente y positiva de la segunda, en la dirección de Ácido Málico y Fenoles No Flavonoides, indicando una mayor presencia relativa de estas características y valores más bajos en los compuestos fenólicos asociados a la Dimensión 1, que caracterizan a la Clase 1.

La Clase 2 aparece principalmente en la parte inferior del gráfico, asociada a valores negativos de la segunda componente, en oposición a variables como Intensidad del Color, Cenizas y Alcohol. Además, algunas observaciones de esta clase se ven ligeramente influenciadas por variables como Alcalinidad de las Cenizas, que aparecen próximas a su región. En conjunto, la separación entre clases se explica principalmente por el gradiente de compuestos fenólicos en la primera dimensión y por variables relacionadas con el color, las cenizas y el alcohol en la segunda.